

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
Факультет прикладной информатики и компьютерных технологий
Кафедра информационных технологий

КУРСОВАЯ РАБОТА

на тему:

**«Разработка системы автоматизированного сбора и первичной
обработки данных из внешнего API с использованием Apache Airflow и
объектного хранилища»**

Выполнил:

студент

Л. Судиловский

Группа:

Руководитель:

Дата защиты:

«___» _____ 2026 г.

Минск, 2026

ОГЛАВЛЕНИЕ

Оглавление обновляется автоматически

ВВЕДЕНИЕ

Актуальность темы определяется тем, что современные аналитические системы всё чаще работают не с одним заранее структурированным источником, а с множеством внешних API, журналов, файлов и потоков событий. Такие данные имеют разную структуру, поступают с разной периодичностью и могут использоваться не только для отчётности, но и для последующего машинного обучения. При этом простой перенос данных напрямую в реляционную базу данных не решает задачу долгосрочного хранения исходных снимков, повторной обработки и масштабирования хранилища при росте количества источников.

В работе рассматривается архитектура Data Lakehouse для автоматизированного сбора и первичной обработки данных из внешнего API. Практический прототип реализует первый слой такой архитектуры: Apache Airflow по расписанию запускает процесс извлечения данных OpenSky Network API, DuckDB выполняет первичное чтение и преобразование ответа, а результат сохраняется в S3-совместимое объектное хранилище MinIO в формате Parquet. OpenSky используется как открытый источник реальных авиационных ADS-B данных, позволяющий продемонстрировать работу с полу-структурированным JSON и снимками состояния внешней системы.

Объектом исследования является процесс построения ETL/ELT-конвейера для сбора данных из внешних API в Big Data архитектуре. Предметом исследования является проектирование и реализация bronze-слоя Data Lakehouse на базе Apache Airflow, DuckDB, Parquet и S3-совместимого объектного хранилища.

Цель работы — разработать и обосновать архитектуру системы автоматизированного сбора и первичной обработки данных из внешнего API, ориентированную на дальнейшее развитие до Data Lakehouse для большого количества источников данных.

Для достижения цели поставлены следующие задачи:

- проанализировать существующие архитектуры аналитических хранилищ данных и определить место Data Lakehouse среди них;
- обосновать необходимость объектного хранилища и raw/bronze-слоя вместо загрузки исходных данных только в PostgreSQL;
- рассмотреть технологический стек Lakehouse и выбрать инструменты под требования прототипа;
- спроектировать архитектуру ETL-конвейера, правила хранения, партиционирования и именования файлов;
- реализовать DAG Airflow для загрузки данных OpenSky Network API в S3-совместимое хранилище;
- проверить развёртывание инфраструктуры, импорт DAG, запись в MinIO и поведение системы при отказе внешнего API;
- сформулировать ограничения прототипа и направления развития до полноценной Big Data платформы.

Методы исследования включают анализ документации Apache Airflow, DuckDB, MinIO и OpenSky Network API, сравнительный анализ архитектур хранилищ данных, проектирование компонентной архитектуры, контейнерное развёртывание и практическую проверку работы прототипа.

Практическая значимость работы состоит в том, что созданный прототип является не отдельным скриптом загрузки данных, а первым модулем расширяемой Lakehouse-платформы. В дальнейшем к нему можно подключать новые API, строить silver- и gold-слои, добавлять витрины для BI и наборы данных для ML-задач.

Курсовая работа состоит из введения, трёх глав, заключения, списка использованных источников и приложений. В первой главе рассматриваются теоретические основы Data Lakehouse и ETL-конвейеров. Во второй главе проектируется архитектура разрабатываемой системы. В третьей главе описывается программная реализация и тестирование прототипа.

1 Теоретические основы Data Lakehouse и ETL-конвейеров

1.1. Обзор существующих архитектур аналитических хранилищ данных

Классическое хранилище данных (DWH) строится вокруг заранее спроектированной схемы и загрузки очищенных данных в реляционную или колоночную СУБД. Подход Inmon предполагает централизованное корпоративное хранилище с нормализованной моделью, из которого формируются зависимые витрины. Подход Kimball ориентируется на размерные модели и витрины по бизнес-процессам. Оба подхода хорошо подходят для регламентированной отчётности, но требуют ранней фиксации схемы и не предназначены для дешёвого хранения всех исходных файлов из большого числа разнородных источников.

Data Lake первого поколения возник как ответ на рост объёмов и разнообразия данных. В Hadoop-экосистеме данные сохранялись в распределённом файловом хранилище, а схема применялась при чтении (schema-on-read). Это позволяло хранить JSON, CSV, логи и бинарные файлы без предварительного моделирования. Ограничением ранних Data Lake стала проблема «болота данных»: без каталогизации, качества и транзакционных гарантий хранилище быстро теряет управляемость.

Lambda-архитектура разделяет batch- и speed-слои: исторические данные обрабатываются пакетно, а свежие события — потоково. Карра-архитектура упрощает этот подход и строит обработку вокруг единого потока событий. Эти архитектуры актуальны для real-time задач, но для рассматриваемого проекта ежедневного или периодического ingest из API достаточно batch/ELT-подхода с возможностью дальнейшего расширения.

Data Lakehouse объединяет преимущества Data Lake и DWH: данные хранятся в объектном хранилище в открытых форматах, а поверх них могут строиться таблицы, транзакционные слои, витрины и SQL-доступ. В отличие от чистого DWH, Lakehouse допускает хранение исходных полуструктурированных данных. В отличие от неуправляемого Data Lake, он

предполагает слои данных, метаданные, контроль качества и воспроизводимые пайплайны.

Data Mesh развивает идею децентрализации: данные рассматриваются как продукты, а ответственность за них распределяется между доменными командами. Для данного курсового проекта Data Mesh является перспективным направлением, но не основной архитектурой, поскольку реализуется один источник и один прототип ingest-конвейера.

Таблица 1 – Сравнение архитектур и технологий для задач multi-source ingestion

Подход	Где уместен	Вывод для проекта
RDBMS / PostgreSQL-only	Прикладные таблицы, транзакции, справочники, небольшие витрины	Не лучший primary raw-слой для множества API: нужна ранняя схема, сложнее хранить дешёвый файловый архив и подключать разные compute-движки
Классический DWH	Регламентированная отчётность и согласованная модель предприятия	Сильный serving/gold-слой, но raw-данные разной структуры лучше сначала приземлять в lake/lakehouse
Data Lake	Дешёвое хранение любых файлов и schema-on-read	Нужны правила слоёв, качество и метаданные, иначе появляется неуправляемое “болото данных”
Lakehouse	Multi-source ingest, хранение raw + развитие до BI/ML	Лучший базовый вариант для проекта: bronze/silver/gold, открытые форматы, разделение storage/compute
Kafka/Flink streaming	События в реальном времени и минимальная задержка	Для периодического API-ingest избыточно как основа; может добавиться позже для streaming-источников
ClickHouse serving	Быстрые OLAP-запросы и дашборды по подготовленным данным	Хорош для gold/serving-слоя, но не заменяет raw-архив и повторную обработку
NoSQL document/key-value	Гибкое хранение документов или быстрые lookup-сценарии	Не является универсальной аналитической архитектурой для Parquet/S3 и SQL-обработки

1.2. Обоснование выбора архитектуры Data Lakehouse

Для разрабатываемой системы выбран подход Data Lakehouse, потому что задача относится к классу multi-source API ingestion: данные приходят из внешних систем, имеют полу-структурированный формат, могут поступать с разной периодичностью и должны сохраняться так, чтобы их можно было повторно обработать при изменении бизнес-логики. Для такого класса задач базовой архитектурой целесообразно делать не одну прикладную базу

данных, а отдельный raw/bronze-слой на объектном хранилище с открытыми форматами.

Классический DWH хорошо подходит для стабильной отчётности, когда данные уже очищены и модель предметной области согласована. Поточковая архитектура Kafka/Flink уместна, когда нужны события в реальном времени и задержки в секунды. ClickHouse эффективен как высокопроизводительный аналитический serving-слой. NoSQL-хранилища подходят для быстрых key-value или document-сценариев. Локальная файловая система применима только для простых автономных запусков. В рассматриваемой задаче требуется прежде всего надёжный ingest, хранение исходных снимков, расширение на новые источники и последующая аналитика, поэтому Lakehouse является более сбалансированным вариантом.

OpenSky Network API возвращает полу-структурированный JSON, где полезная нагрузка представлена массивом state vectors. Такой источник демонстрирует типичный сценарий внешнего API: данные могут содержать отсутствующие значения, обновляться независимо от локальной системы и требовать сохранения снимка на момент получения. Lakehouse-подход позволяет сохранить такой снимок в bronze-слое, а затем уже строить типизированные silver-таблицы и агрегированные gold-витрины.

Реляционные СУБД, включая PostgreSQL, в такой архитектуре не исключаются, но занимают другое место: они могут хранить метаданные, справочники, результаты агрегирования или обслуживать витрины. Однако raw-архив большого количества внешних источников рациональнее хранить в объектном хранилище, потому что оно дешевле масштабируется по объёму, не требует немедленной фиксации схемы и остаётся доступным для разных вычислительных движков: DuckDB, Spark, Trino, ClickHouse или BI-инструментов.

Ограничения проекта также влияют на выбор. Требуется open source стек, локальное развёртывание и возможность показать архитектуру без облачной инфраструктуры. Поэтому вместо управляемого AWS S3

используется MinIO, вместо распределённого Spark-кластера на первом этапе — DuckDB, а вместо промышленного secret backend — Airflow Variables с описанием дальнейшего перехода к Connections и Secrets API.

1.3. Medallion-архитектура bronze / silver / gold

Medallion-архитектура делит данные на несколько уровней зрелости. Bronze-слой хранит исходные снимки из источников. Silver-слой содержит очищенные, типизированные и нормализованные данные. Gold-слой содержит витрины, агрегаты и наборы данных, готовые для BI, аналитики и ML. Такое разделение снижает связность между ingest и аналитическими сценариями.

В данной курсовой реализуется именно bronze-слой. Это не означает, что проект ограничивается учебной загрузкой файла. Напротив, bronze-слой является обязательной основой масштабируемого Lakehouse: если завтра появятся новые источники или изменятся правила расчётов, исходные данные можно перечитать и заново построить производные слои. Без bronze-слоя система теряет возможность воспроизводимого backfill и аудита исходных данных.

Silver- и gold-слои рассматриваются как направления развития. В silver-слое state vector OpenSky должен быть разобран на именованные поля: icao24, callsign, origin_country, time_position, last_contact, longitude, latitude, velocity и другие. В gold-слое могут появиться витрины по странам, временным интервалам, высоте, скорости или зонам наблюдения.

Data Lakehouse: разделение хранения и вычислений




Рисунок 1 – Логика Data Lakehouse и medallion-слоёв

1.4. Современный технологический стек Lakehouse

Технологический стек Lakehouse обычно включает объектное хранилище, открытый формат хранения, оркестратор, движок обработки, слой метаданных и инструменты контроля качества. В качестве объектных хранилищ применяются AWS S3, MinIO, Ceph и совместимые облачные сервисы. Их преимущество — независимое масштабирование хранения, работа с файлами разных типов и стандартный API для большого числа инструментов.

Для аналитического хранения используются Parquet и ORC, а для табличных Lakehouse-слоёв — Iceberg, Delta Lake и Hudi. Parquet выбран в прототипе как базовый колоночный формат: он хорошо подходит для последующего чтения SQL-движками и не требует развёртывания дополнительного table format слоя. Iceberg, Delta Lake или Hudi целесообразно добавить на следующем этапе, когда появятся silver/gold-таблицы, schema evolution и транзакционные операции над наборами данных.

Системы оркестрации — Airflow, Prefect и Dagster — отвечают за расписание, зависимости и наблюдаемость. Движки обработки — Spark, Trino, DuckDB, ClickHouse — решают разные задачи. Spark нужен для распределённой обработки больших объёмов, Trino — для федеративных

SQL-запросов, ClickHouse — для высокопроизводительной аналитической выдачи, DuckDB — для локальной SQL-обработки файлов и API-снимков на первом этапе.

При выборе стека важно не подменять архитектурное решение отдельным инструментом. Для хранения raw-данных лучше использовать объектное хранилище и файлы Parquet/ORC, для регулярного запуска — оркестратор, для тяжёлых преобразований — распределённый движок, для быстрой выдачи агрегатов — аналитическую СУБД или DWH-витрину. В курсовом проекте реализуется первый этап этой цепочки: автоматический ingest и сохранение bronze-слоя.

Таблица 2 – Выбор инструментов по инженерным критериям

Слой	Выбранный инструмент	Альтернативы	Причина выбора
Оркестрация	Apache Airflow	Cron, Prefect, Dagster	Для регулярного API-ingest лучше workflow-оркестратор с retry, backfill, логами и состоянием задач; cron подходит только для простых одиночных запусков.
Raw-хранилище	MinIO / S3 API	Локальная FS, HDFS, Ceph, AWS S3, RDBMS	Для такого класса задач лучше объектное хранилище: оно масштабируется по объёму и не привязывает raw-данные к конкретной СУБД.
Обработка bronze	DuckDB	Spark, pandas, Trino	На первом этапе лучше лёгкий SQL-движок без кластера; Spark/Trino уместны при росте объёмов и числа хранилищ.
Аналитический формат	Parquet + ZSTD	JSON, CSV, ORC, Avro	Для последующей аналитики лучше колоночный формат; JSON/CSV полезны для обмена, но хуже для массового чтения.
Table format на будущее	Iceberg / Delta / Hudi	Обычные Parquet-файлы	Нужны при schema evolution, ACID, upsert и time travel; для начального bronze-слоя достаточно Parquet.
Serving-слой на будущее	ClickHouse / DWH / BI	Прямое чтение raw	Агрегированные данные лучше отдавать из подготовленных витрин, а не из сырого API-

			архива.
--	--	--	---------

1.5. Apache Airflow: архитектура и ключевые концепции

Apache Airflow предоставляет модель DAG, в которой workflow описывается как направленный ациклический граф задач. Для Big Data ingestion важны не только сами строки кода загрузки, но и эксплуатационные свойства: retry, backfill, журналирование, ограничение параллельности, история запусков и единый интерфейс мониторинга. Именно эти свойства отличают промышленный data pipeline от разового Python-скрипта.

Архитектура Airflow включает webserver, scheduler, executor, worker-процессы, metadata database и набор операторов. Scheduler анализирует DAG-файлы и создаёт экземпляры задач, executor передаёт их на выполнение, worker выполняет код, а metadata database хранит состояние запусков. Благодаря этому pipeline описывается декларативно и становится наблюдаемым: для каждого запуска доступны статус, логи, длительность и история повторных попыток.

Apache Airflow выбран по эксплуатационным требованиям к ingest-процессу в Big Data системе: такой процесс должен быть управляемым объектом, а не разовым запуском скрипта. Для него нужны расписание, повторные попытки, backfill, контроль зависимостей, журналирование и возможность масштабировать выполнение задач. Эти свойства особенно важны при подключении нескольких источников, где отказ одного API не должен разрушать весь контур обработки.

1.6. Источник данных OpenSky Network

OpenSky Network является открытой сетью сбора ADS-B данных о воздушных судах. API предоставляет state vectors — снимки состояния воздушных судов, включающие идентификаторы, временные метки, координаты, скорость, курс и другие параметры. Для курсовой работы этот источник выбран как реальный внешний API с полу-структурированным

JSON и эксплуатационными рисками: сетевые задержки, ограничения доступности и неполнота отдельных полей.

С точки зрения Lakehouse источник OpenSky важен тем, что его ответ не является заранее нормализованной таблицей. Полезная нагрузка представлена массивами, часть значений может отсутствовать, а семантика полей задаётся внешней документацией API. Это типичный случай, когда raw-снимок необходимо сначала сохранить в bronze-слое, а уже затем применять типизацию и бизнес-правила в silver/gold слоях.

1.7. Выводы по главе 1

Для системы, ориентированной на рост количества источников и последующее развитие до BI/ML платформы, архитектура Lakehouse обоснованнее, чем прямая загрузка всех исходных данных в PostgreSQL. PostgreSQL может использоваться как metadata/serving-компонент, но raw-слой целесообразно строить на объектном хранилище и открытых форматах.

2 Проектирование ETL-конвейера

2.1. Постановка задачи и требования

Разрабатываемая система должна автоматически получать данные из OpenSky Network API, выполнять первичную техническую обработку ответа и сохранять результат в bronze-слое объектного хранилища. Функционально система должна поддерживать запуск по расписанию, ручной запуск, повторные попытки при сбое источника, хранение результата по дате интервала и проверку статуса выполнения.

Нефункциональные требования связаны с Lakehouse-архитектурой: хранение должно масштабироваться независимо от вычислений, формат должен быть пригоден для последующей аналитики, схема должна допускать развитие, а инфраструктура должна разворачиваться локально на open source компонентах. Отдельно учитывается безопасность: секреты доступа к S3 не должны храниться в Git и должны передаваться через конфигурацию Airflow.

Таблица 3 – Требования к системе и реализация

Тип	Требование	Реализация
Функциональное	Получение данных из внешнего API	DAG Airflow + DuckDB read_json_auto
Функциональное	Сохранение raw-снимков	MinIO bucket bronze, Parquet
Функциональное	Запуск по расписанию и вручную	Airflow schedule_interval и UI
Нефункциональное	Расширение на много источников	Каталоги source/dt и объектное хранилище
Нефункциональное	Повторная обработка/backfill	Логические интервалы Airflow и raw-архив
Нефункциональное	Отказоустойчивость	retries, retry_delay, логи задач
Безопасность	Секреты вне Git	Airflow Variables/Connections, .gitignore

2.2. Архитектурная схема системы

Архитектура включает внешний источник OpenSky Network API, Apache Airflow как оркестратор, DuckDB как движок первичной ELT-обработки, MinIO как S3-совместимое объектное хранилище, PostgreSQL как базу метаданных Airflow и Redis как брокер CeleryExecutor. Airflow webserver предоставляет UI, scheduler создаёт запуски, worker выполняет PythonOperator, а DuckDB внутри worker читает JSON и записывает Parquet в MinIO.

Такое разделение компонентов важно для Big Data архитектуры. Хранение данных отделено от вычисления, поэтому рост объёма raw-слоя не требует масштабировать PostgreSQL как основное хранилище. Airflow хранит только метаданные процесса, а сами данные размещаются в S3-совместимом bucket. Это позволяет в будущем подключать Spark, Trino или другие движки к тем же файлам без переноса данных.

Архитектура ETL-конвейера и протоколы взаимодействия

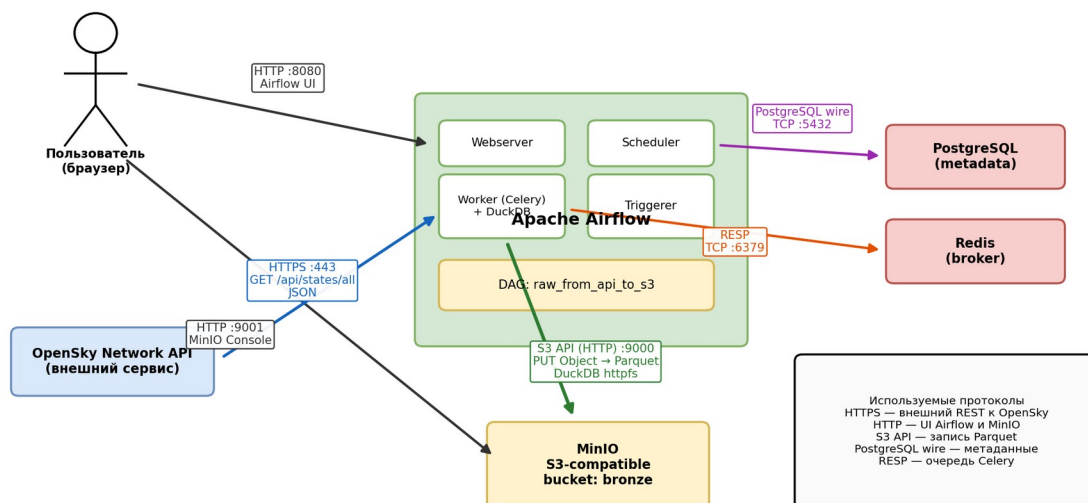


Рисунок 2 – Архитектурная схема ETL-конвейера

2.3. Логическая модель данных bronze-слоя

Исходный ответ OpenSky имеет JSON-структуру: верхнеуровневое поле `time` фиксирует время ответа, а поле `states` содержит массив `state vectors`. Каждый `state vector` является массивом значений, где позиция элемента соответствует определённому признаку воздушного судна. На `bronze`-уровне допустимо сохранять данные близко к источнику, но для последующего `silver`-слоя требуется типизированная схема.

Целевая схема Parquet для развития проекта должна включать как минимум поля `snapshot_ts`, `ingestion_ts`, `icao24`, `callsign`, `origin_country`, `time_position`, `last_contact`, `longitude`, `latitude`, `baro_altitude`, `on_ground`, `velocity`, `true_track`, `vertical_rate`, `sensors`, `geo_altitude`, `squawk`, `spi`, `position_source`. Поле `snapshot_ts` описывает время снимка источника, а `ingestion_ts` — время загрузки в систему. Такое разделение важно для аудита: источник мог сформировать данные раньше, чем pipeline их записал.

В текущем прототипе сохраняется результат первичного разворачивания массива `states`. Это соответствует роли `bronze`-слоя: не

потерять исходную информацию и подготовить основу для последующего типизированного silver-преобразования.

Таблица 4 – Целевая схема silver-слоя для данных OpenSky

Поле	Тип	Назначение
snapshot_ts	timestamp	Время снимка источника
ingestion_ts	timestamp	Время загрузки в Lakehouse
icao24	string	ICAO 24-bit адрес
callsign	string	Позывной воздушного судна
origin_country	string	Страна происхождения
longitude / latitude	double	Географические координаты
baro_altitude / geo_altitude	double	Высота
velocity / true_track	double	Скорость и курс
on_ground	boolean	Признак нахождения на земле

2.4. Стратегия партиционирования и именования файлов

Файлы сохраняются в bucket bronze по логическому пути raw/opensky/<date>/<date>_00-00-00.parquet. Такой путь отражает источник, слой и дату интервала. Для будущего промышленного варианта предпочтительно использовать Hive-style партиционирование: source=opensky/dt=YYYY-MM-DD/hour=HH/. Этот подход распознаётся многими движками обработки и упрощает чтение только нужных дат.

Именованье файлов должно быть детерминированным. Если запуск за один интервал повторяется, результат должен попадать в тот же логический раздел, а не создавать набор случайных файлов. Это снижает риск дублей и облегчает backfill. При переходе к нескольким запускам в час можно добавить run_id или ingestion_ts в имя объекта, сохранив партицию по дате.

2.5. Обоснование выбора инструментов под задачу

Для задач автоматического сбора данных из внешних API оптимальная базовая схема выглядит как «оркестратор + объектное хранилище + открытый аналитический формат + вычислительный движок». Оркестратор отвечает за расписание и отказоустойчивость, объектное хранилище — за масштабируемое хранение raw-снимков, файловый формат — за эффективное последующее чтение, а вычислительный движок — за

преобразование данных. Остальные технологии могут подключаться как специализированные слои, но не заменяют всю схему целиком.

MinIO выбран как локальная реализация S3-совместимого объектного хранилища. Для такого рода задач лучше использовать S3-совместимый storage, потому что он отделяет хранение от вычислений и позволяет подключать разные движки к одним и тем же файлам. Локальная файловая система проще, но хуже переносится в распределённую среду. HDFS требует отдельной Hadoop-инфраструктуры. Serp подходит для более крупного self-hosted кластера. Облачный AWS S3 является промышленным аналогом, но для курсового стенда MinIO воспроизводит тот же API локально.

Apache Airflow выбран как оркестратор. Для регулярного batch-ingest из API лучше использовать систему workflow orchestration, а не cron или ручной запуск скрипта: нужны зависимости, retry, backfill, история запусков, логи и UI. Prefect и Dagster также подходят для современных data pipelines, но Airflow выбран как распространённый стандарт в batch ETL/ELT и как инструмент, хорошо показывающий архитектуру scheduler, worker, metadata database и executor.

DuckDB выбран как движок ETL для первого bronze-этапа, потому что он поддерживает чтение JSON, запись Parquet и работу с S3 через httpfs без отдельного кластера. Для массовой распределённой обработки в дальнейшем лучше использовать Spark. Для федеративных запросов по нескольким хранилищам уместен Trino. Для быстрых аналитических витрин — ClickHouse. Для текущего ingest одного API-снимка эти инструменты избыточны как обязательная часть первого слоя, но архитектура сохраняет возможность подключить их позже.

Parquet выбран как формат хранения, потому что для аналитических данных лучше применять колоночные форматы с компрессией, а не CSV или произвольный JSON как основной формат чтения. JSON целесообразно сохранять как исходный контракт API, но для запросов и последующей обработки Parquet эффективнее по размеру и скорости чтения. Для будущего

развития поверх Parquet можно добавить Iceberg, Delta Lake или Hudi, если появятся требования к ACID-операциям, schema evolution, upsert и time travel.

2.6. Проектирование DAG

DAG `raw_from_api_to_s3` состоит из трёх задач: `start`, `get_and_transfer_api_data_to_s3` и `end`. Центральная задача получает интервал Airflow, настраивает DuckDB `httpfs`, читает OpenSky API и записывает результат в MinIO. Расписание `0 5 * * *` задаёт ежедневный запуск, `retries = 3` и `retry_delay =` один час обеспечивают реакцию на временную недоступность внешнего API.

Поток задач намеренно минимален: отдельные `start` и `end` задачи фиксируют границы `workflow`, а центральная задача содержит операцию `ingest`. При расширении проекта между `start` и `end` можно добавить проверки доступности источника, валидацию схемы, запись технических метрик, построение `silver`-слоя и публикацию `gold`-витрин. Поэтому текущий DAG является начальной точкой расширяемого конвейера, а не изолированным скриптом.

Расписание `0 5 * * *` задаёт ежедневный запуск после завершения календарных суток, что упрощает хранение файлов по датам. Параметры `retries = 3` и `retry_delay =` один час отражают природу внешнего API: временная недоступность источника должна приводить не к потере данных, а к повторной попытке в рамках управляемого `workflow`.

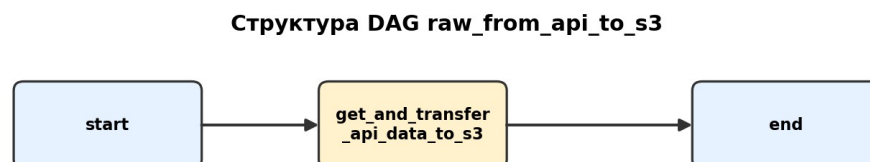


Рисунок 3 – Структура DAG `raw_from_api_to_s3`

2.7. Безопасность

Безопасность проектируется на нескольких уровнях. На уровне Git секреты не попадают в репозиторий: .env, cred.py, logs и data исключены через .gitignore. На уровне Airflow ключи доступа задаются как Variables; в дальнейшем их следует перенести в Airflow Connections или secret backend. На уровне сети контейнеры взаимодействуют внутри Docker network, а MinIO S3 API доступен worker-процессу по имени сервиса minio:9000. Для production необходимо включить TLS, отдельные сервисные access keys и политики минимальных прав.

DuckDB при работе с S3 использует параметры endpoint, access_key_id, secret_access_key и режим url_style. В прототипе эти параметры передаются из Airflow-конфигурации, а не фиксируются в публичном коде как реальные секреты. Такой подход соответствует принципу разделения кода и конфигурации: DAG описывает процесс, а значения доступов задаются средой выполнения.

2.8. Выводы по главе 2

Архитектура прототипа соответствует роли первого модуля Data Lakehouse. Она отделяет raw-хранилище от метаданных Airflow, сохраняет данные в открытом формате и допускает подключение новых источников и движков обработки без изменения базовой идеи.

3 Программная реализация и тестирование

3.1. Развёртывание инфраструктуры в Docker Compose

Инфраструктура проекта разворачивается с помощью docker-compose.yml. В состав входят сервисы minio, postgres, redis, airflow-webserver, airflow-scheduler, airflow-worker, airflow-triggerer и airflow-init. Такая конфигурация основана на официальной схеме Apache Airflow для CeleryExecutor и показывает распределённую модель выполнения задач:

scheduler планирует, Redis передаёт задачи, worker исполняет, PostgreSQL хранит метаданные.

В исходном учебном проекте также присутствовали DWH PostgreSQL и Metabase, однако в данной курсовой они не включены в активную часть, потому что реализуется bronze-ingest слой. Это не противоречит Lakehouse-архитектуре: DWH/BI относится к gold/serving-уровню и может быть подключён позже, когда появятся очищенные и агрегированные наборы данных.

3.2. Реализация DAG raw_from_api_to_s3

DAG расположен в файле dags/raw_from_api_to_S3.py. В нём заданы идентификатор raw_from_api_to_s3, владелец L.sudilovskiy, слой raw и источник opensky. Функция get_dates получает data_interval_start и data_interval_end из контекста Airflow. Это важнее, чем использование текущей системной даты, потому что Airflow работает с логическими интервалами и может выполнять backfill за прошлые даты.

Функция get_and_transfer_api_data_to_s3 создаёт соединение DuckDB, загружает расширение httpfs, настраивает S3 endpoint и выполняет SQL COPY. В запросе read_json_auto читает внешний JSON, unnest(states) разворачивает массив состояний, а COPY TO сохраняет результат в Parquet. Таким образом, Python используется для оркестрации вызова, а сама операция чтения/записи описана декларативно через SQL.

Ключевой фрагмент SQL-запроса DuckDB:

```
COPY                                (
                                     SELECT
                                     time,
                                     state
                                     FROM   read_json_auto('https://opensky-network.org/api/states/all')
                                     unnest(states)      as
                                     's3://bronze/raw/opensky/{start_date}/{start_date}_00-00-00.parquet';
                                     ) TO
```

3.3. Конфигурация Airflow и инициализация хранилища

Для работы DAG в Airflow должны быть заданы переменные access_key и secret_key. В учебном стенде они соответствуют локальным ключам MinIO, но в отчёте реальные секреты не раскрываются. Bucket bronze

создаётся в MinIO перед запуском DAG. В промышленной версии создание bucket и политик доступа должно быть вынесено в инфраструктурный код или init-задачу, чтобы стенд разворачивался воспроизводимо.

Airflow UI используется для включения DAG, ручного запуска, просмотра статусов и логов. MinIO Console используется для проверки наличия bucket и объектов. Эти интерфейсы не являются частью бизнес-логики, но важны для эксплуатации: оператор должен видеть, какой запуск выполнен, где возник сбой и появился ли объект в хранилище.

3.4. Тестирование прототипа

Smoke-тест парсинга DAG выполнен командой `python3 -m ru_compile dags/raw_from_api_to_S3.py`. Также Airflow успешно импортировал DAG без `import errors`. Функциональная проверка инфраструктуры показала, что контейнеры Airflow, PostgreSQL, Redis и MinIO запускаются, а Airflow отображает DAG `raw_from_api_to_s3`.

Проверка результата в MinIO выполнялась через контрольную запись Parquet-файла DuckDB в bucket `bronze`. Это подтвердило, что S3 endpoint, ключи доступа, расширение `httpfs` и сетевое взаимодействие `worker` → MinIO настроены корректно. При live-запуске DAG внешний OpenSky API дал `timeout` на HTTP HEAD, после чего Airflow перевёл задачу в состояние `up_for_retry`. Такой результат трактуется как проверка сценария отказа источника: `retry`-политика сработала штатно.

Идемпотентность обеспечивается детерминированным путём записи по дате интервала. Повторный запуск за один интервал должен формировать объект в том же логическом разделе. Для production следует усилить этот механизм: сначала писать во временный путь, затем атомарно публиковать результат, а также добавлять проверки размера файла и количества строк.

Результаты практической проверки прототипа

1

Docker Compose поднял Airflow, PostgreSQL, Redis и MinIO

успешно

2

Airflow обнаружил DAG raw_from_api_to_s3 без ошибок импорта

успешно

3

Airflow Variables access_key и secret_key заданы для S3-доступа

успешно

4

DuckDB записал тестовый Parquet-файл в bucket bronze через S3 API

успешно

5

Запуск DAG дошёл до обращения к OpenSky API и ушёл в retry при таймауте

ожидаемая обработка сбоя

Вывод:

локальная инфраструктура и запись в S3-совместимое хранилище подтверждены;
таймаут внешнего API показал работу retry-механизма Airflow и отражён как эксплуатационный риск.

Рисунок 4 – Сводка результатов проверки

Apache Airflow UI

DAGs

DAG: raw_from_api_to_s3

is_paused: False

Task	Operator	State	Description
start	EmptyOperator	success	Начальный маркер запуска
get_and_transfer_api_data_to_s3	PythonOperator	up_for_retry	Загрузка OpenSky API → MinIO/S3
end	EmptyOperator	none	Конечный маркер DAG

Результат тестового запуска

DAG обнаружен Airflow без import errors; задача стартовала и перешла в retry из-за таймаута внешнего OpenSky API.
Это подтверждает работоспособность оркестрации и демонстрирует штатную обработку временной недоступности API.
Секреты S3 настроены через Airflow Variables и не выводятся в отчёт.

Рисунок 5 – Проверка DAG в Airflow

MinIO Consolebucket: bronze

Object browser / bronze

Object key	Type	Status	Purpose
raw/opensky/<date>/<date>_00-00-00.parquet	Parquet	ожидаемый результат Data	raw/bronze слой
test/test.parquet	Parquet	создан проверкой S3-записи	проверка DuckDB → MinIO
logs/	directory	ignored by Git	служебные логи Airflow
data/	directory	ignored by Git	локальное хранилище MinIO

Проверка результата

Bucket bronze создан; запись Parquet через DuckDB https в MinIO проверена отдельной командой.

Боевой объект raw/opensky формируется при успешной доступности внешнего OpenSky API.

Рисунок 6 – Проверка bucket bronze в MinIO

3.5. Анализ полученных данных

Данные OpenSky представляют собой реальные наблюдения воздушных судов. В рамках курсовой реализован первый этап работы с ними — получение и сохранение снимка в bronze-слой. Потенциальная структура silver-слоя включает координаты, высоту, скорость, курс, страну происхождения и временные метки. На основе этих данных можно строить статистику по активности воздушного пространства, распределению стран, средним скоростям и зонам наблюдения.

Для bronze-слоя важны не столько агрегированные показатели, сколько полнота и воспроизводимость снимка. Значение поля time связывается с моментом формирования ответа источника, а дата интервала Airflow — с логическим периодом загрузки. Такое разделение позволяет позже анализировать задержки ingest, строить повторные загрузки и сравнивать снимки по календарным периодам.

Полученные данные являются основой для последующей аналитики. В silver-слое массив state должен быть разложен на именованные признаки, очищен от технических пропусков и дополнен метаданными snapshot_ts и ingestion_ts. В gold-слое на их основе могут быть построены витрины по

активности воздушного пространства, временным интервалам, странам происхождения и характеристикам движения.

3.6. Обнаруженные ограничения и направления развития

Основное ограничение текущей реализации — отсутствие полного silver/gold контуров. Также отсутствуют расширенные проверки качества, алерты, schema registry и транзакционный table format. Эти ограничения являются естественными для первого реализованного bronze-слоя, но прямо задают направление развития для ВКР: добавить типизацию state vectors, Iceberg/Delta/Hudi, DWH/BI serving-слой, мониторинг SLA, data quality checks и поддержку нескольких источников.

Перспективным развитием является подключение нескольких источников: погодных API, справочников аэропортов, данных о рейсах и географических зон. Именно в таком сценарии Lakehouse-подход раскрывается сильнее всего: новые источники добавляются как новые raw-разделы, а общие аналитические витрины строятся поверх согласованных silver-таблиц.

3.7. Выводы по главе 3

Реализованный прототип подтверждает возможность построения первого слоя Data Lakehouse на open source стеке. Он автоматизирует ingest из внешнего API, использует объектное хранилище и Parquet, а также демонстрирует эксплуатационные свойства Airflow: импорт DAG, планирование, retry и наблюдаемость.

ЗАКЛЮЧЕНИЕ

В ходе курсовой работы была переработана и обоснована архитектура системы автоматизированного сбора и первичной обработки данных из внешнего API в логике Data Lakehouse. Основной акцент сделан на построении масштабируемого bronze-слоя, который в будущем может

принимать данные из большого количества источников и служить основой для silver/gold аналитических слоёв.

Показано, что загрузка исходных данных только в PostgreSQL не является оптимальным архитектурным решением для Big Data ingestion. PostgreSQL полезен для метаданных, serving-слоя и витрин, но raw-архив множества полу-структурированных источников рациональнее хранить в объектном хранилище в открытых форматах. Такой подход обеспечивает разделение хранения и вычислений, schema-on-read, backfill и возможность подключения разных движков обработки.

Для прототипа выбран стек Apache Airflow, DuckDB, MinIO, Parquet, PostgreSQL и Redis. Выбор каждого инструмента обоснован требованиями к архитектуре: Airflow отвечает за управляемую оркестрацию, MinIO — за S3-совместимое raw-хранилище, DuckDB — за лёгкий ELT-процесс первого этапа, Parquet — за аналитический файловый формат, PostgreSQL и Redis — за внутреннюю работу Airflow CeleryExecutor.

Практическая проверка подтвердила импорт DAG, работоспособность инфраструктуры и возможность записи Parquet в MinIO. Таймаут внешнего OpenSky API показал важность retry-механизма и обработки отказов внешнего источника. В дальнейшем проект может быть расширен до полноценного Lakehouse с silver/gold слоями, Iceberg или Delta Lake, несколькими источниками, проверками качества и BI/ML сценариями.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Apache Airflow Documentation. Dags [Электронный ресурс]. – Режим доступа: <https://airflow.apache.org/docs/apache-airflow/stable/core-concepts/dags.html>. – Дата доступа: 20.05.2026.
2. Apache Airflow Documentation. Running Airflow in Docker [Электронный ресурс]. – Режим доступа: <https://airflow.apache.org/docs/apache-airflow/stable/howto/docker-compose/index.html>. – Дата доступа: 20.05.2026.

3. DuckDB Documentation. httpfs extension and S3 API [Электронный ресурс].
 – Режим доступа: https://duckdb.org/docs/stable/core_extensions/httpfs/s3api.html. – Дата доступа: 20.05.2026.
4. MinIO Documentation. Object Store [Электронный ресурс]. – Режим доступа: <https://docs.min.io/community/minio-object-store/>. – Дата доступа: 20.05.2026.
5. OpenSky Network API Documentation [Электронный ресурс]. – Режим доступа: <https://opensky-network.org/data/api-docs>. – Дата доступа: 20.05.2026.
6. Korsakov I. Pet project earthquake [Электронный ресурс]. – Режим доступа: https://github.com/k0rsakov/pet_project_earthquake. – Дата доступа: 20.05.2026.
7. ГОСТ 7.32–2017. СИБИД. Отчет о научно-исследовательской работе. Структура и правила оформления.
8. ГОСТ 7.1–2003. Библиографическая запись. Библиографическое описание. Общие требования и правила составления.
9. Методические рекомендации по оформлению курсовых и дипломных работ / Институт бизнеса БГУ. – Минск : БГУ, 2020. – 36 с.
10. Inmon W. H. Building the Data Warehouse. – Wiley, 2005.
11. Kimball R., Ross M. The Data Warehouse Toolkit. – Wiley, 2013.
12. Armbrust M. et al. Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics // CIDR, 2021.

ПРИЛОЖЕНИЕ А

Полный листинг DAG raw_from_api_to_S3.py

```

import logging
import duckdb
import pendulum
from airflow import DAG
from airflow.models import Variable
from airflow.operators.empty import EmptyOperator
from airflow.operators.python import PythonOperator

# Конфигурация DAG
OWNER = "L.sudilovskiy"
DAG_ID = "raw_from_api_to_s3"

# Используемые таблицы в DAG
LAYER = "raw"
SOURCE = "opensky"

# S3
ACCESS_KEY = Variable.get("access_key")
SECRET_KEY = Variable.get("secret_key")

LONG_DESCRIPTION = """
# LONG DESCRIPTION
"""

SHORT_DESCRIPTION = "SHORT DESCRIPTION"

args = {
    "owner": OWNER,
    "start_date": pendulum.datetime(2026, 5, 1, tz="Europe/Moscow"),
    "catchup": True,
    "retries": 3,
    "retry_delay": pendulum.duration(hours=1),
}

def get_dates(**context) -> tuple[str, str]:
    """
    start_date = context["data_interval_start"].format("YYYY-MM-DD")
    end_date = context["data_interval_end"].format("YYYY-MM-DD")
    return start_date, end_date

def get_and_transfer_api_data_to_s3(**context):
    """
    start_date, end_date = get_dates(**context)
    logging.info(f"Start load for dates: {start_date}/{end_date}")
    con = duckdb.connect()

    con.sql(
        f"""
        SET TIMEZONE='UTC';
        INSTALL httpfs;
        LOAD httpfs;
        SET s3_url_style = 'path';
        SET s3_endpoint = 'minio:9000';
        SET s3_access_key_id = '{ACCESS_KEY}';
        SET s3_secret_access_key = '{SECRET_KEY}';
        SET s3_use_ssl = FALSE;

        COPY
        (
        SELECT
        time,
        unnest(states) as state
        FROM
        read_json_auto('https://opensky-network.org/api/states/all')
        ) TO 's3://bronze/{LAYER}/{SOURCE}/{start_date}/{start_date}_00-00-00.parquet';
        """
    )

    con.close()

```

```

logging.info(f"Download for date success: {start_date}")

with DAG(
    dag_id=DAG_ID,
    schedule_interval="@0 5 *",
    default_args=args,
    tags=["s3", "raw"],
    description=SHORT_DESCRIPTION,
    concurrency=1,
    max_active_tasks=1,
    max_active_runs=1,
) as dag:
    dag.doc_md = LONG_DESCRIPTION

    start = EmptyOperator(
        task_id="start",
    )

    get_and_transfer_api_data_to_s3 = PythonOperator(
        task_id="get_and_transfer_api_data_to_s3",
        python_callable=get_and_transfer_api_data_to_s3,
    )

    end = EmptyOperator(
        task_id="end",
    )

    start >> get_and_transfer_api_data_to_s3 >> end

```

ПРИЛОЖЕНИЕ Б

Полный листинг docker-compose.yaml

```
# Licensed to the Apache Software Foundation (ASF) under one
# or more contributor license agreements. See the NOTICE file
# distributed with this work for additional information
# regarding copyright ownership. The ASF licenses this file
# to you under the Apache License, Version 2.0 (the
# "License"); you may not use this file except in compliance
# with the License. You may obtain a copy of the License at
#
# http://www.apache.org/licenses/LICENSE-2.0
#
# Unless required by applicable law or agreed to in writing,
# software distributed under the License is distributed on an
# "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY
# KIND, either express or implied. See the License for the
# specific language governing permissions and limitations
# under the License.

# Basic Airflow cluster configuration for CeleryExecutor with Redis and PostgreSQL.
#
# WARNING: This configuration is for local development. Do not use it in a production
# deployment.
#
# This configuration supports basic configuration using environment variables or an .env file
# The following variables are supported:
#
# AIRFLOW_IMAGE_NAME - Docker image name used to run Airflow.
#                      Default: apache/airflow:2.10.5
# AIRFLOW_UID - User ID in Airflow containers
#               Default: 50000
# AIRFLOW_PROJ_DIR - Base path to which all the files will be volumed.
#                   Default: .
# Those configurations are useful mostly in case of standalone testing/running Airflow in
# test/try-out mode
#
# _AIRFLOW_WWW_USER_USERNAME - Username for the administrator account (if requested).
#                               Default: airflow
# _AIRFLOW_WWW_USER_PASSWORD - Password for the administrator account (if requested).
#                               Default: airflow
# _PIP_ADDITIONAL_REQUIREMENTS - Additional PIP requirements to add when starting all
#                               containers.
#                               Use this option ONLY for quick checks. Installing requirements
#                               at container
#                               startup is done EVERY TIME the service is started.
#                               A better way is to build a custom image or extend the official
#                               image as described in
#                               https://airflow.apache.org/docs/docker-stack/build.html.
#                               Default: ''
#
# Feel free to modify this file to suit your needs.
---
x-airflow-common:
  &airflow-common
  # In order to add custom dependencies or upgrade provider packages you can use your extended
  # image.
  # Comment the image line, place your Dockerfile in the directory where you placed the docker-
  # compose.yaml
  # and uncomment the "build" line below, Then run `docker-compose build` to build the images.
  image: ${AIRFLOW_IMAGE_NAME:-apache/airflow:2.10.5}
  build:
    .
  environment:
    &airflow-common-env
    AIRFLOW__CORE__EXECUTOR: CeleryExecutor
    AIRFLOW__DATABASE__SQL_ALCHEMY_CONN: postgresql+psycopg2://airflow:airflow@postgres/airflow
    AIRFLOW__CELERY__RESULT_BACKEND: db+postgresql://airflow:airflow@postgres/airflow
    AIRFLOW__CELERY__BROKER_URL: redis://:@redis:6379/0
    AIRFLOW__CORE__FERNET_KEY: ''
    AIRFLOW__CORE__DAGS_ARE_PAUSED_AT_CREATION: 'true'
    AIRFLOW__CORE__LOAD_EXAMPLES: 'false'
    AIRFLOW__API__AUTH_BACKENDS:
      'airflow.api.auth.backend.basic_auth,airflow.api.auth.backend.session'
  #
  # yamllint disable rule:line-length
```

```

# Use simple http server on scheduler for health checks
# See https://airflow.apache.org/docs/apache-airflow/stable/administration-and-deployment/
logging-monitoring/check-health.html#scheduler-health-check-server
# yamllint enable rule:line-length
# AIRFLOW__SCHEDULER__ENABLE_HEALTH_CHECK: 'true'
# WARNING: Use _PIP_ADDITIONAL_REQUIREMENTS option ONLY for a quick checks
# for other purpose (development, test and especially production usage) build/extend
Airflow image.
# The following line can be used to set a custom config file, stored in the local config
folder
# If you want to use it, uncomment it and replace airflow.cfg with the name of your config
file
# AIRFLOW_CONFIG: '/opt/airflow/config/airflow.cfg'
# volumes:
# - ${AIRFLOW_PROJ_DIR:-.}/dags:/opt/airflow/dags
# - ${AIRFLOW_PROJ_DIR:-.}/logs:/opt/airflow/logs
# - ${AIRFLOW_PROJ_DIR:-.}/config:/opt/airflow/config
# - ${AIRFLOW_PROJ_DIR:-.}/plugins:/opt/airflow/plugins
# user: "${AIRFLOW_UID:-50000}:0"
# depends_on:
# &airflow-common-depends-on
# redis:
# condition: service_healthy
# postgres:
# condition: service_healthy

services:
# postgres_dwh:
# image: postgres:13
# environment:
# POSTGRES_USER: postgres
# POSTGRES_PASSWORD: postgres
# POSTGRES_DB: postgres
# restart: always
# ports:
# - "5432:5432"
# minio:
# image: minio/minio:RELEASE.2025-02-18T16-25-55Z
# restart: always
# volumes:
# - ./data:/data
# environment:
# - MINIO_ROOT_USER=minioadmin
# - MINIO_ROOT_PASSWORD=minioadmin
# command: server /data --console-address ":9001"
# ports:
# - "9000:9000"
# - "9001:9001"
# metabase:
# build:
# context: .
# dockerfile: ./metabase/Dockerfile
# container_name: metabase
# ports:
# - "3000:3000"
# postgres:
# image: postgres:13
# environment:
# POSTGRES_USER: airflow
# POSTGRES_PASSWORD: airflow
# POSTGRES_DB: airflow
# volumes:
# - postgres-db-volume:/var/lib/postgresql/data
# healthcheck:
# test: ["CMD", "pg_isready", "-U", "airflow"]
# interval: 10s
# retries: 5
# start_period: 5s
# restart: always
# redis:
# Redis is limited to 7.2-bookworm due to licencing change
# https://redis.io/blog/redis-adopts-dual-source-available-licensing/
# image: redis:7.2-bookworm
# expose:
# - 6379
# healthcheck:

```

```

test:      ["CMD",      "redis-cli",      "ping"]
            interval:      10s
            timeout:        30s
            retries:        50
            start_period:   30s
            restart:        always

            airflow-webserver:
<<:      *airflow-common
            command:        webserver
            ports:          8080:8080
            healthcheck:
test:      ["CMD",      "curl",      "--fail",      "http://localhost:8080/health"]
            interval:      30s
            timeout:        10s
            retries:        5
            start_period:   30s
            restart:        always
            depends_on:
<<:      *airflow-common-depends-on
            airflow-init:
            condition:      service_completed_successfully

            airflow-scheduler:
<<:      *airflow-common
            command:        scheduler
            healthcheck:
test:      ["CMD",      "curl",      "--fail",      "http://localhost:8974/health"]
            interval:      30s
            timeout:        10s
            retries:        5
            start_period:   30s
            restart:        always
            depends_on:
<<:      *airflow-common-depends-on
            airflow-init:
            condition:      service_completed_successfully

            airflow-worker:
<<:      *airflow-common
            command:        celery
            worker
            healthcheck:
            #      yamllint      disable      rule:line-length
            test:
            -      "CMD-SHELL"
            - 'celery --app airflow.providers.celery.executors.celery_executor.app inspect ping -d "celery@${HOSTNAME}" || celery --app airflow.executors.celery_executor.app inspect ping -d "celery@${HOSTNAME}"'
            interval:      30s
            timeout:        10s
            retries:        5
            start_period:   30s
            environment:
<<:      *airflow-common-env
            # Required to handle warm shutdown of the celery workers properly
            # See https://airflow.apache.org/docs/docker-stack/entrypoint.html#signal-propagation
            DUMB_INIT_SETSID: "0"
            restart:        always
            depends_on:
<<:      *airflow-common-depends-on
            airflow-init:
            condition:      service_completed_successfully

            airflow-triggerer:
<<:      *airflow-common
            command:        triggerer
            healthcheck:
test:      ["CMD-SHELL", 'airflow jobs check --job-type TriggererJob --hostname "${HOSTNAME}"]
            interval:      30s
            timeout:        10s
            retries:        5
            start_period:   30s
            restart:        always
            depends_on:
<<:      *airflow-common-depends-on
            airflow-init:
            condition:      service_completed_successfully

```

```

                                airflow-init:
                                <<: *airflow-common
                                entrypoint: /bin/bash
                                # yamllint disable rule:line-length
                                command:
                                - -c
                                |
                                if [[ -z "${AIRFLOW_UID}" ]]; then
                                echo
                                echo -e "\033[1;33mWARNING!!!: AIRFLOW_UID not set!\e[0m"
                                echo "If you are on Linux, you SHOULD follow the instructions below to set "
                                echo "AIRFLOW_UID environment variable, otherwise files will be owned by root."
                                echo "For other operating systems you can get rid of the warning with manually
created .env file:"
                                echo " See: https://airflow.apache.org/docs/apache-airflow/stable/howto/docker-
compose/index.html#setting-the-right-airflow-user"
                                fi
                                one_meg=1048576
                                mem_available=$((($(getconf _PHYS_PAGES) * $(getconf PAGE_SIZE) / one_meg))
                                cpus_available=$(grep -cE 'cpu[0-9]+' /proc/stat)
                                disk_available=$(df / | tail -1 | awk '{print $4}')
                                warning_resources="false"
                                if (( mem_available < 4000 )) ; then
                                echo
                                echo -e "\033[1;33mWARNING!!!: Not enough memory available for Docker.\e[0m"
                                echo "At least 4GB of memory required. You have $(numfmt --to iec $(mem_available
                                one_meg)))"
                                warning_resources="true"
                                fi
                                if (( cpus_available < 2 )); then
                                echo
                                echo -e "\033[1;33mWARNING!!!: Not enough CPUS available for Docker.\e[0m"
                                echo "At least 2 CPUS recommended. You have ${cpus_available}"
                                warning_resources="true"
                                fi
                                if (( disk_available < one_meg * 10 )); then
                                echo
                                echo -e "\033[1;33mWARNING!!!: Not enough Disk space available for Docker.\e[0m"
                                echo "At least 10 GBs recommended. You have $(numfmt --to iec $(disk_available *
                                1024)))"
                                warning_resources="true"
                                fi
                                if [[ ${warning_resources} == "true" ]]; then
                                echo
                                echo -e "\033[1;33mWARNING!!!: You have not enough resources to run Airflow (see
                                above)!\e[0m"
                                echo "Please follow the instructions to increase amount of resources available:"
                                echo " https://airflow.apache.org/docs/apache-airflow/stable/howto/docker-compose/
                                index.html#before-you-begin"
                                fi
                                mkdir -p /sources/logs /sources/dags /sources/plugins
                                chown -R "${AIRFLOW_UID}:0" /sources/{logs,dags,plugins}
                                # exec /entrypoint airflow version
                                yamllint enable rule:line-length
                                environment:
                                <<: *airflow-common-env
                                _AIRFLOW_DB_MIGRATE: 'true'
                                _AIRFLOW_WWW_USER_CREATE: 'true'
                                _AIRFLOW_WWW_USER_USERNAME: ${_AIRFLOW_WWW_USER_USERNAME:-airflow}
                                _AIRFLOW_WWW_USER_PASSWORD: ${_AIRFLOW_WWW_USER_PASSWORD:-airflow}
                                _PIP_ADDITIONAL_REQUIREMENTS: ''
                                user: "0:0"
                                volumes:
                                - ${AIRFLOW_PROJ_DIR:-.}:/sources
                                <<: *airflow-common
                                profiles:
                                - debug
                                environment:
                                <<: *airflow-common-env
                                CONNECTION_CHECK_MAX_COUNT: "0"
                                # Workaround for entrypoint issue. See: https://github.com/apache/airflow/issues/16252
                                command:
                                - bash

```

```

-C
- airflow

# You can enable flower by adding "--profile flower" option e.g. docker-compose --profile
flower up
# or by explicitly targeted on the command line e.g. docker-compose up flower.
# See: https://docs.docker.com/compose/profiles/

flower:
  <<: *airflow-common
  command: celery
  profiles:
    - flower
  ports:
    - "5555:5555"
  healthcheck:
    test: ["CMD", "curl", "--fail", "http://localhost:5555/"]
    interval: 30s
    timeout: 10s
    retries: 5
    start_period: 30s
  restart: always
  <<: *airflow-common-depends-on
    airflow-init:
  condition: service_completed_successfully

volumes:
  postgres-db-volume:

```


ПРИЛОЖЕНИЕ В

Конфигурационные файлы req.txt и .gitignore

В.1 req.txt

```
apache-airflow==2.10.5
duckdb==1.2.2
```

В.2 .gitignore

```
# Byte-compiled / optimized / DLL files
__pycache__/
*.py[cod]
*$py.class

# C extensions
*.so

# Distribution / packaging
.Python
build/
develop-eggs/
dist/
downloads/
eggs/
.eggs/
lib/
lib64/
parts/
sdist/
var/
wheels/
share/python-wheels/
*.egg-info/
.installed.cfg
*.egg
MANIFEST

# PyInstaller
# Usually these files are written by a python script from a template
# before PyInstaller builds the exe, so as to inject date/other infos into it.
*.manifest
*.spec

# Installer logs
pip-log.txt
pip-delete-this-directory.txt

# Unit test / coverage reports
htmlcov/
.tox/
.nox/
.coverage
.coverage.*
.cache
nosetests.xml
coverage.xml
*.cover
*.py.cover
.hypothesis/
.pytest_cache/
cover/

# Translations
*.mo
*.pot

# Django stuff:
*.log
local_settings.py
```

```

db.sqlite3
db.sqlite3-journal

# Flask stuff:
instance/
.webassets-cache

# Scrapy stuff:
.scrapy

# Sphinx documentation
docs/_build/

# PyBuilder
.pybuilder/
target/

# Jupyter Notebook
.ipynb_checkpoints

# IPython
profile_default/
ipython_config.py

# pyenv
# For a library or package, you might want to ignore these files since the code is
# intended to run in multiple environments; otherwise, check them in:
# .python-version

# pipenv
# According to pypa/pipenv#598, it is recommended to include Pipfile.lock in version control.
# However, in case of collaboration, if having platform-specific dependencies or dependencies
# having no cross-platform support, pipenv may install dependencies that don't work, or not
# install all needed dependencies.
# Pipfile.lock

# UV
# Similar to Pipfile.lock, it is generally recommended to include uv.lock in version control.
# This is especially recommended for binary packages to ensure reproducibility, and is more
# commonly ignored for libraries.
# uv.lock

# poetry
# Similar to Pipfile.lock, it is generally recommended to include poetry.lock in version
# control.
# This is especially recommended for binary packages to ensure reproducibility, and is more
# commonly ignored for libraries.
# https://python-poetry.org/docs/basic-usage/#commit-your-poetrylock-file-to-version-control
# poetry.lock
# poetry.toml

# pdm
# Similar to Pipfile.lock, it is generally recommended to include pdm.lock in version
# control.
# pdm recommends including project-wide configuration in pdm.toml, but excluding .pdm-python.
# https://pdm-project.org/en/latest/usage/project/#working-with-version-control
# pdm.lock
# pdm.toml
.pdm-python
.pdm-build/

# pixi
# Similar to Pipfile.lock, it is generally recommended to include pixi.lock in version
# control.
# pixi.lock
# Pixi creates a virtual environment in the .pixi directory, just like venv module creates
# one in the .venv directory. It is recommended not to include this directory in version control.
# .pixi

# PEP 582; used by e.g. github.com/David-OConnor/pyflow and github.com/pdm-project/pdm
__pypackages__

# Celery stuff
celerybeat-schedule
celerybeat.pid

# Redis
*.rdb
*.aof

```

```

*.pid

#
mnesia/
rabbitmq/
rabbitmq-data/

#
activemq-data/

#
SageMath
*.sage.py
parsed
files

#
Environments
.env
.envrc
.venv
env/
venv/
ENV/
env.bak/
venv.bak/

#
Spyder
project
settings
.spyderproject
.spyproject

#
Rope
project
settings
.ropeproject

#
mkdocs
documentation
/site

#
mypy
.mypy_cache/
.dmypy.json
dmypy.json

#
Pyre
type
checker
.pyre/

#
pytype
static
type
analyzer
.pytype/

#
Cython
debug
symbols
cython_debug/

#
PyCharm
# JetBrains specific template is maintained in a separate JetBrains.gitignore that can
# be found at https://github.com/github/gitignore/blob/main/Global/JetBrains.gitignore
# and can be added to the global gitignore or merged into this file. For a more nuclear
# option (not recommended) you can uncomment the following to ignore the entire idea folder.
#
.idea/

#
Abstra
# Abstra is an AI-powered process automation framework.
# Ignore directories containing user credentials, local state, and settings.
# Learn more at https://abstra.io/docs
.abstra/

#
Visual Studio Code
# Visual Studio Code specific template is maintained in a separate VisualStudioCode.gitignore
# that can be found at
https://github.com/github/gitignore/blob/main/Global/VisualStudioCode.gitignore
# and can be added to the global gitignore or merged into this file. However, if you prefer,
# you could uncomment the following to ignore the entire vscode folder
#
.vscode/
# Temporary file for partial code execution
tempCodeRunnerFile.py

#
Ruff
stuff:
.ruff_cache/

#
PyPI
configuration
file
.pypirc

#
Marimo
marimo/_static/
marimo/_lsp/
__marimo__/

```

```
#  
.streamlit/secrets.toml  
  
data/  
logs/  
cred.py
```

Streamlit

ПРИЛОЖЕНИЕ Г

Скриншоты результатов практической проверки

Результаты практической проверки прототипа

- 1 Docker Compose поднял Airflow, PostgreSQL, Redis и MinIO успешно
- 2 Airflow обнаружил DAG raw_from_api_to_s3 без ошибок импорта успешно
- 3 Airflow Variables access_key и secret_key заданы для S3-доступа успешно
- 4 DuckDB записал тестовый Parquet-файл в bucket bronze через S3 API успешно
- 5 Запуск DAG дошёл до обращения к OpenSky API и ушёл в retry при таймауте ожидаемая обработка сбоя

Вывод: локальная инфраструктура и запись в S3-совместимое хранилище подтверждены;
таймаут внешнего API показал работу retry-механизма Airflow и отражён как эксплуатационный риск.

Рисунок Г.1 – Сводка проверки прототипа

Apache Airflow UI

DAGs

DAG: raw_from_api_to_s3

is_paused: False

Task	Operator	State	Description
start	EmptyOperator	success	Начальный маркер запуска
get_and_transfer_api_data_to_s3	PythonOperator	up_for_retry	Загрузка OpenSky API → MinIO/S3
end	EmptyOperator	none	Конечный маркер DAG

Результат тестового запуска

DAG обнаружен Airflow без import errors; задача стартовала и перешла в retry из-за таймаута внешнего OpenSky API.

Это подтверждает работоспособность оркестрации и демонстрирует штатную обработку временной недоступности API.

Секреты S3 настроены через Airflow Variables и не выводятся в отчёт.

Рисунок Г.2 – DAG и статусы задач в Airflow

MinIO Console

bucket: bronze

Object browser / bronze

Object key	Type	Status	Purpose
raw/opensky/<date>/<date>_00-00-00.parquet	Parquet	ожидаемый результат DDL	raw/bronze слой
test/test.parquet	Parquet	создан проверкой S3-записи	проверка DuckDB → MinIO
logs/	directory	ignored by Git	служебные логи Airflow
data/	directory	ignored by Git	локальное хранилище MinIO

Проверка результата

Bucket bronze создан; запись Parquet через DuckDB https в MinIO проверена отдельной командой.

Боевой объект raw/opensky формируется при успешной доступности внешнего OpenSky API.

Рисунок Г.3 – Структура bucket bronze в MinIO